Hospital Patient Records

Struktur, relasi, dan panduan eksplorasi infografis

Dataset ini merupakan data pasien sintetis berbasis Synthea yang disediakan untuk Maven Hospital Challenge. Data bukan rekam medis pasien nyata dan tidak dapat dipakai untuk menyimpulkan kinerja aktual Massachusetts General Hospital. Berkas diunduh dari tautan arsip publik resmi Maven pada 22 Oktober 2026.

Tabel	Unit per baris	Baris	Kolom
patients	Satu pasien sintetis	974	20
encounters	Satu kunjungan / episode layanan	27.891	14
procedures	Satu catatan tindakan / prosedur	47.701	9
payers	Satu penanggung biaya, termasuk NO_INSURANCE	10	7
organizations	Satu organisasi penyedia layanan	1	8

Apa yang perlu diketahui sejak awal

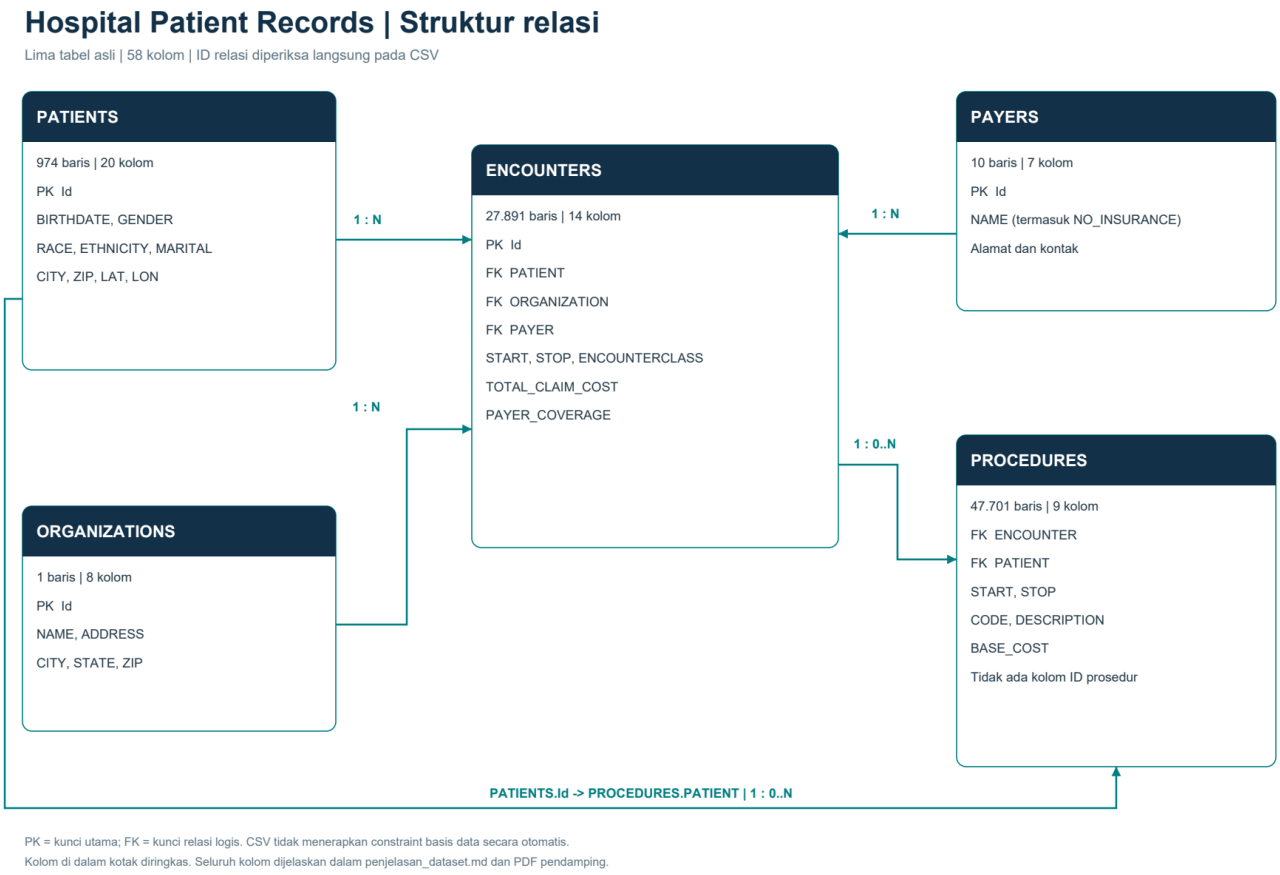
Lima tabel, 58 kolom. Total baris lintas tabel adalah 76.577; angka ini bukan jumlah pasien. Periode mulai kunjungan aktual adalah 2 Januari 2011 hingga 5 Februari 2022.

Kamus sumber mencantumkan Middle dan FIPS County Code pada patients, tetapi kedua kolom tidak terdapat pada CSV aktual. Dokumentasi ini mengikuti berkas yang diunduh.

Lima hubungan antar-ID telah diperiksa: tidak ditemukan ID anak tanpa induk. Tidak ada baris identik pada lima tabel. Nilai kosong tetap ada pada atribut tertentu dan dibahas menurut maknanya.

Halaman resmi Maven Hospital Challenge
Tautan unduhan arsip resmi Maven

Peta relasi lima tabel



Cara membaca relasi

patients, organizations, dan payers terhubung ke encounters. Setiap kunjungan dapat memiliki nol atau banyak catatan procedures. procedures juga menyimpan PATIENT yang merujuk langsung ke patients.

793 pasien dan **14.670 kunjungan** mempunyai catatan prosedur. Sebanyak 181 pasien dan 13.221 kunjungan tidak memiliki baris prosedur. Gunakan left join bila seluruh pasien atau kunjungan harus dipertahankan.

Id unik tersedia pada empat tabel induk. Procedures tidak memiliki kolom ID prosedur eksplisit; CODE bukan kunci unik. PK dan FK pada diagram adalah kunci logis yang diperiksa pada CSV.

Penggabungan prosedur dengan kunjungan memakai ENCOUNTER = Id. Join hanya melalui PATIENT dapat memasangkan satu prosedur dengan kunjungan lain milik pasien yang sama.

Kamus tabel: patients

Satu pasien sintetis. 974 baris dan 20 kolom. Tipe di bawah adalah tipe analitis yang disarankan.

Kolom asli	Tipe	Makna	Kosong
Id	Teks / kategori	ID unik tabel; kunci utama.	0
BIRTHDATE	Tanggal	Tanggal lahir pasien (YYYY-MM-DD).	0
DEATHDATE	Tanggal	Tanggal kematian bila tercatat; kosong bukan nilai nol.	820
PREFIX	Teks / kategori	Sapaan / gelar sebelum nama.	0
FIRST	Teks / kategori	Nama depan sintetis.	0
LAST	Teks / kategori	Nama keluarga sintetis.	0
SUFFIX	Teks / kategori	Gelar / penanda setelah nama; opsional.	953
MAIDEN	Teks / kategori	Nama sebelum menikah; opsional.	588
MARITAL	Teks / kategori	Status pernikahan; M = menikah, S = lajang.	1
RACE	Teks / kategori	Kategori ras yang tercatat.	0
ETHNICITY	Teks / kategori	Kategori etnis yang tercatat.	0
GENDER	Teks / kategori	Kode gender pada sumber; F = perempuan, M = laki-laki.	0
BIRTHPLACE	Teks / kategori	Tempat lahir sintetis.	0
ADDRESS	Teks / kategori	Alamat yang tercatat.	0
CITY	Teks / kategori	Kota pada alamat.	0
STATE	Teks / kategori	Negara bagian pada alamat.	0
COUNTY	Teks / kategori	Wilayah county pada alamat.	0
ZIP	Teks / kategori	Kode pos; simpan sebagai teks agar nol di depan terjaga.	142
LAT	Desimal	Lintang lokasi.	0
LON	Desimal	Bujur lokasi.	0

DEATHDATE, SUFFIX, dan MAIDEN dapat kosong sesuai konteks. Jangan menghapus seluruh pasien hanya karena kolom opsional tidak terisi. ZIP sebaiknya disimpan sebagai teks.

Kamus tabel: encounters

Satu kunjungan / episode layanan. 27.891 baris dan 14 kolom. Tipe di bawah adalah tipe analitis yang disarankan.

Kolom asli	Tipe	Makna	Kosong
Id	Teks / kategori	ID unik tabel; kunci utama.	0
START	Tanggal-waktu	Waktu mulai layanan, format ISO 8601 UTC.	0
STOP	Tanggal-waktu	Waktu selesai layanan, format ISO 8601 UTC.	0
PATIENT	Teks / kategori	ID pasien; merujuk patients.Id.	0
ORGANIZATION	Teks / kategori	ID organisasi; merujuk organizations.Id.	0
PAYER	Teks / kategori	ID penanggung biaya; merujuk payers.Id.	0
ENCOUNTERCLASS	Teks / kategori	Kategori layanan yang tercatat; enam kategori aktual.	0
CODE	Teks / kategori	Kode layanan atau tindakan SNOMED-CT. Simpan sebagai teks.	0
DESCRIPTION	Teks / kategori	Deskripsi kode layanan atau tindakan.	0
BASE_ENCOUNTER_COST	Desimal	Biaya dasar kunjungan, tidak termasuk rincian layanan tambahan (USD).	0
TOTAL_CLAIM_COST	Desimal	Total biaya kunjungan beserta rincian layanannya (USD).	0
PAYER_COVERAGE	Desimal	Nilai biaya yang tercatat ditanggung penjamin (USD).	0
REASONCODE	Teks / kategori	Kode alasan / kondisi SNOMED-CT; dapat kosong.	19.541
REASONDESCRIPTION	Teks / kategori	Deskripsi alasan / kondisi; dapat kosong.	19.541

TOTAL_CLAIM_COST sudah mencakup item layanan. REASONCODE kosong berarti alasan spesifik tidak tercatat pada kolom ini, bukan tidak ada kondisi kesehatan.

Kamus tabel: procedures

Satu catatan tindakan / prosedur. 47.701 baris dan 9 kolom. Tipe di bawah adalah tipe analitis yang disarankan.

Kolom asli	Tipe	Makna	Kosong
START	Tanggal-waktu	Waktu mulai layanan, format ISO 8601 UTC.	0
STOP	Tanggal-waktu	Waktu selesai layanan, format ISO 8601 UTC.	0
PATIENT	Teks / kategori	ID pasien; merujuk patients.Id.	0
ENCOUNTER	Teks / kategori	ID kunjungan; merujuk encounters.Id.	0
CODE	Teks / kategori	Kode layanan atau tindakan SNOMED-CT. Simpan sebagai teks.	0
DESCRIPTION	Teks / kategori	Deskripsi kode layanan atau tindakan.	0
BASE_COST	Desimal	Biaya item prosedur (USD).	0
REASONCODE	Teks / kategori	Kode alasan / kondisi SNOMED-CT; dapat kosong.	36.945
REASONDESCRIPTION	Teks / kategori	Deskripsi alasan / kondisi; dapat kosong.	36.945

Satu kunjungan dapat memiliki banyak baris. Tidak semua kunjungan mempunyai prosedur. PATIENT seluruh prosedur konsisten dengan pasien pada ENCOUNTER yang dirujuk.

Kamus tabel: payers

Satu penanggung biaya, termasuk NO_INSURANCE. 10 baris dan 7 kolom. Tipe di bawah adalah tipe analitis yang disarankan.

Kolom asli	Tipe	Makna	Kosong
Id	Teks / kategori	ID unik tabel; kunci utama.	0
NAME	Teks / kategori	Nama organisasi atau penanggung biaya.	0
ADDRESS	Teks / kategori	Alamat yang tercatat.	1
CITY	Teks / kategori	Kota pada alamat.	1
STATE_HEADQUARTERED	Teks / kategori	Negara bagian alamat kantor penanggung biaya.	1
ZIP	Teks / kategori	Kode pos; simpan sebagai teks agar nol di depan terjaga.	1
PHONE	Teks / kategori	Nomor telepon; simpan sebagai teks.	1

Terdapat kategori NO_INSURANCE. Kontaknya kosong, tetapi ID-nya tetap terisi dan valid. Kategori ini jangan dianggap sebagai foreign key yang hilang.

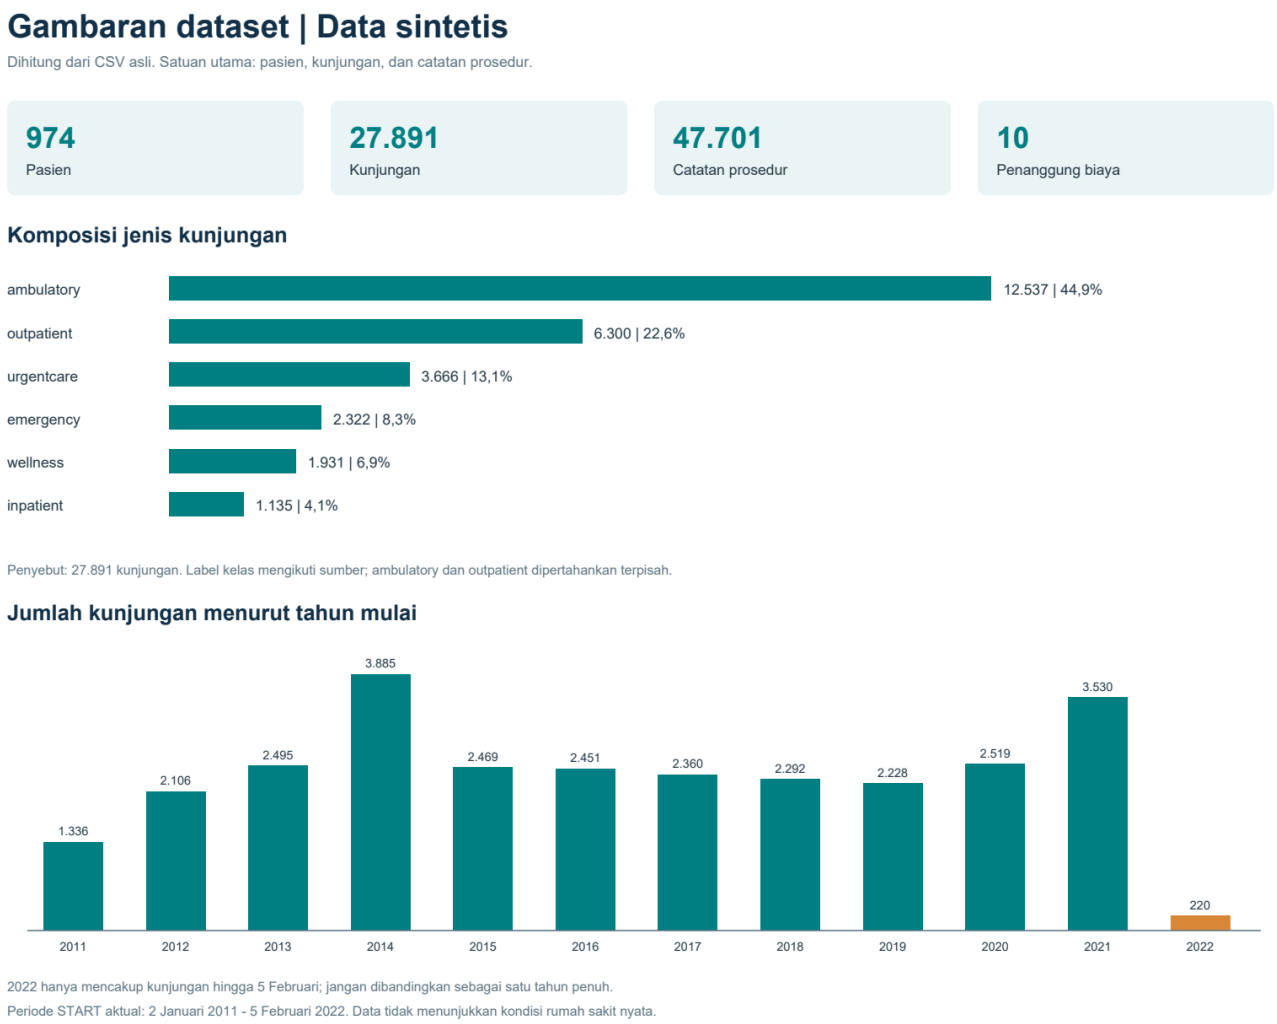
Kamus tabel: organizations

Satu organisasi penyedia layanan. 1 baris dan 8 kolom. Tipe di bawah adalah tipe analitis yang disarankan.

Kolom asli	Tipe	Makna	Kosong
Id	Teks / kategori	ID unik tabel; kunci utama.	0
NAME	Teks / kategori	Nama organisasi atau penanggung biaya.	0
ADDRESS	Teks / kategori	Alamat yang tercatat.	0
CITY	Teks / kategori	Kota pada alamat.	0
STATE	Teks / kategori	Negara bagian pada alamat.	0
ZIP	Teks / kategori	Kode pos; simpan sebagai teks agar nol di depan terjaga.	0
LAT	Desimal	Lintang lokasi.	0
LON	Desimal	Bujur lokasi.	0

Hanya satu organisasi tercatat, sehingga dataset ini tidak mendukung perbandingan kinerja antar-rumah sakit.

Visualisasi awal



Grafik dihitung dari encounters asli. Tidak ada penggandaan baris melalui join. Kategori ambulatory dan outpatient dipertahankan terpisah sesuai label sumber.

Tahun 2022 hanya hingga 5 Februari. Penurunan jumlah pada batang terakhir tidak dapat dibaca sebagai penurunan tahunan penuh. Seluruh catatan bersifat sintetis.

Aturan analisis

Pilih unit analisis sebelum menggabungkan tabel.

Gunakan patients untuk menghitung orang, encounters untuk kunjungan, dan procedures untuk catatan tindakan. Jumlah baris hasil join bukan otomatis jumlah pasien.

Hindari penggandaan biaya.

Satu kunjungan dapat memiliki banyak prosedur. Menjumlahkan TOTAL_CLAIM_COST setelah join langsung ke procedures akan menggandakan biaya kunjungan. Ringkas prosedur per ENCOUNTER sebelum join atau hitung biaya di tabel encounters.

Hubungkan prosedur melalui ENCOUNTER.

Untuk mengaitkan tindakan dengan kunjungan, gunakan procedures.ENCOUNTER = encounters.Id. Join hanya melalui PATIENT akan memasangkan tindakan dengan kunjungan lain milik pasien yang sama.

Jangan menjumlahkan komponen biaya yang bertumpang tindih.

TOTAL_CLAIM_COST sudah mencakup item layanan. BASE_ENCOUNTER_COST dan BASE_COST prosedur memiliki cakupan berbeda; jangan menambahkan semuanya sebagai total baru.

Bedakan cakupan penjamin dari pengeluaran pasien.

PAYER_COVERAGE adalah nilai cakupan yang tercatat. Selisih TOTAL_CLAIM_COST - PAYER_COVERAGE boleh disebut biaya yang tidak tercakup pada catatan ini, bukan otomatis pembayaran tunai pasien atau utang yang sudah tertagih.

Kunjungan berulang bukan otomatis readmisi klinis.

Tetapkan definisi episode, jenis rawat inap, urutan keluar-masuk, serta jendela waktu bila ingin menghitung readmisi. Jangan menyebut semua pasien dengan beberapa kunjungan sebagai pasien readmisi.

Gunakan tanggal yang relevan.

Usia sebaiknya dihitung pada START kunjungan, bukan menggunakan usia saat ini. Durasi = STOP - START; hitung untuk kelas layanan yang sesuai. Data 2022 berhenti pada 5 Februari.

Pertahankan nilai kosong sesuai maknanya.

DEATHDATE kosong berarti tanggal kematian tidak tercatat. SUFFIX dan MAIDEN bersifat opsional; REASONCODE tidak selalu tersedia. Jangan mengganti semua nilai kosong dengan nol atau menghapus semua baris yang tidak lengkap.

Arah eksplorasi dan verifikasi

Fokus	Ukuran yang dapat dihitung	Visual
Profil pemanfaatan layanan	Distribusi jenis kunjungan menurut usia saat kunjungan atau gender; penyebut harus jelas.	Batang berkelompok / 100%
Konsentrasi kunjungan	Jumlah kunjungan per pasien; median, kuartil, dan porsi kunjungan dari kelompok frekuensi tinggi.	Histogram / kurva kumulatif
Cakupan pembiayaan	SUM(PAYER_COVERAGE) / SUM(TOTAL_CLAIM_COST) menurut kelas layanan atau penjamin.	Batang persentase
Perubahan aktivitas layanan	Jumlah kunjungan per tahun atau bulan mulai; bandingkan periode yang setara.	Garis / batang
Durasi dan biaya layanan	Median durasi serta biaya menurut ENCOUNTERCLASS; pisahkan rawat inap.	Boxplot / batang median

Hasil pemeriksaan berkas

ID pada empat tabel yang memiliki Id unik dan terisi. Lima relasi tanpa ID anak yang kehilangan induk. Tidak ditemukan baris identik atau durasi negatif pada kunjungan dan prosedur. Pemeriksaan ini bukan audit klinis lengkap.

Total biaya kunjungan tercatat USD 101.514.375,52; cakupan penjamin USD 31.097.506,99. Rasio jumlah cakupan terhadap jumlah biaya adalah 30,63%, bukan persentase pasien yang ditanggung.

Sumber dan atribusi

Maven Hospital Challenge / Hospital Patient Records; sumber data sintetis: Synthea / SyntheticMass. Halaman Maven mencantumkan Public Domain. CSV asli, kamus, dan arsip unduhan disimpan tanpa perubahan.

Walonoski et al. (2018). Synthea: An approach, method, and software mechanism for generating synthetic patients and the synthetic electronic health care record.

Dokumentasi lengkap: penjelasan_dataset.md. Angka pemeriksaan per kolom dan hash berkas: hasil_pemeriksaan.json.